




Apresentação de projeto

Projeto de Parceria | Semantix

Ellen Rebeca Rodrigues de Araújo

Objetivo:

Descobrir se o desempenho escolar e a frequência do ensino básico e médio influenciam nas notas do curso superior

Variáveis aplicadas ao modelo:

- SSC_Marks: Pontuação no exame SSC (10º ano).;
- HSC_Marks: Pontuação no exame HSC (12º ano);
- Attendance_Percentage: Percentual de presença dos alunos;
- Grade: Desempenho acadêmico na graduação (ensino superior). - TARGET

****OBS:** SSC e HSC são exames padronizados do sistema educacional da Índia. As variáveis representam a pontuação de desempenho obtido pelo estudante nesses exames.**


Etapas do projeto:

- Preparação e leitura de dados com pandas;
- Pré-processamento de dados: análise do comportamento e distribuição das variáveis, tratamentos de dados nulos e outliers;
- Análise Exploratória de Dados (EDA): Compreensão da relação das variáveis através de gráficos com a biblioteca Seaborn e Plotly;
- Separação das variáveis;
- Modelagem e Avaliação: aplicação dos modelos para classificação e previsão.

Matriz de Correlação:

- As variáveis apresentaram baixa correlação nas análises que foram feitas.

PS: college_marks (refere-se a nota do ensino superior), mas não foi usada na modelagem pois é semelhante a Grade.



Modelagem e parametrização:

Alguns modelos foram testados nos dados:

- Random Forest;
- Árvore de Decisão;
- XGBoost;
- SVM;

Posteriormente foram aplicados métodos de melhoria do modelo com GridSearch nas parametrizações.

Resultados:

Como esperado nas análises o modelo apresentou baixa previsão dos dados;

Acurácia de 0.23 no modelo de Random Forest

Random Forest

Relatório de Classificação de Random Forest:

	precision	recall	f1-score	support
0	0.27	0.32	0.29	38
1	0.35	0.28	0.31	47
2	0.24	0.10	0.14	49
3	0.16	0.23	0.19	30
4	0.17	0.25	0.20	36
accuracy			0.23	200
macro avg	0.24	0.24	0.23	200
weighted avg	0.25	0.23	0.23	200

Resultados:

Outros modelos foram testados como o de Árvore de Decisão, que obteve uma acurácia extremamente baixo de 0.17

Árvore de Decisão

Relatório de Classificação:

	precision	recall	f1-score	support
0	0.20	0.24	0.22	38
1	0.24	0.21	0.22	47
2	0.24	0.14	0.18	49
3	0.17	0.23	0.20	30
4	0.04	0.06	0.05	36
accuracy			0.17	200
macro avg	0.18	0.18	0.17	200
weighted avg	0.19	0.17	0.18	200

Resultados:

XGBoost

O modelo de XGBoost teve métricas semelhantes ao de Random Forest, melhorando as previsões para a classe 4;

A acurácia foi de 0.23 semelhante a Random Forest.

Relatório de Classificação				
	precision	recall	f1-score	support
0	0.25	0.32	0.28	38
1	0.29	0.26	0.27	47
2	0.26	0.12	0.17	49
3	0.17	0.27	0.21	30
4	0.20	0.22	0.21	36
accuracy			0.23	200
macro avg	0.23	0.24	0.23	200
weighted avg	0.24	0.23	0.23	200

Resultados:

Por último foi testado o SVM, que também obteve métricas parecidas com Random Forest, com acurácia geral de 0.23 também.

SVM

Relatório de Classificação:

	precision	recall	f1-score	support
0	0.25	0.39	0.31	38
1	0.27	0.32	0.29	47
2	0.30	0.06	0.10	49
3	0.12	0.13	0.13	30
4	0.19	0.22	0.21	36
accuracy			0.23	200
macro avg	0.23	0.23	0.21	200
weighted avg	0.24	0.23	0.21	200

Resultados:

Foram feitas melhorias de hiperparâmetros no modelo, porém houve queda nas métricas. Abaixo as métricas dos modelos com melhoria de parametrização:

XGBoost

Relatório de Classificação:

	precision	recall	f1-score	support
0	0.21	0.29	0.24	38
1	0.30	0.23	0.26	47
2	0.18	0.12	0.15	49
3	0.13	0.17	0.14	30
4	0.16	0.17	0.16	36
accuracy			0.20	200
macro avg	0.19	0.20	0.19	200
weighted avg	0.20	0.20	0.19	200

SVM

Relatório de Classificação com o Melhor Modelo:

	precision	recall	f1-score	support
0	0.15	0.21	0.18	38
1	0.26	0.51	0.34	47
2	0.00	0.00	0.00	49
3	0.00	0.00	0.00	30
4	0.14	0.19	0.16	36
accuracy			0.20	200
macro avg	0.11	0.18	0.14	200
weighted avg	0.11	0.20	0.14	200

Como podemos notar, apesar da melhorias ambos os modelos tiveram queda de acurácia para 0.20

Resultados:

Foram feitas melhorias de hiperparâmetros no modelo, porém houve queda nas métricas. Abaixo as métricas dos modelos com melhoria de parametrização:

XGBoost

Relatório de Classificação:

	precision	recall	f1-score	support
0	0.21	0.29	0.24	38
1	0.30	0.23	0.26	47
2	0.18	0.12	0.15	49
3	0.13	0.17	0.14	30
4	0.16	0.17	0.16	36
accuracy			0.20	200
macro avg	0.19	0.20	0.19	200
weighted avg	0.20	0.20	0.19	200

SVM

Relatório de Classificação com o Melhor Modelo:

	precision	recall	f1-score	support
0	0.15	0.21	0.18	38
1	0.26	0.51	0.34	47
2	0.00	0.00	0.00	49
3	0.00	0.00	0.00	30
4	0.14	0.19	0.16	36
accuracy			0.20	200
macro avg	0.11	0.18	0.14	200
weighted avg	0.11	0.20	0.14	200

Como podemos notar, apesar da melhorias ambos os modelos tiveram queda de acurácia para 0.20

Resultados

Apesar de terem sido aplicados modelos que são robustos nos dados, eles não conseguiram fazer uma boa previsão, mesmo sendo aplicados parâmetros e outras técnicas, isso provavelmente se deu ou por que os dados não são capazes de classificar a variável target, ou por que não havia dados suficientes que pudessem descrever.

OBS: A base de dados foi obtida na plataforma da Kaggle